Centro Universitário UniFECAF
Disciplina: Disruptive Architectures: IoT, Big Data e IA
Professor(a): Vitor Jansen

Isabelli Moreira Romo Bastos

Pipeline de Dados com IoT, PostgreSQL, Docker e Streamlit

2026

Introdução

Este projeto tem como objetivo implementar um pipeline de dados utilizando um conjunto de dados de Internet das Coisas (IoT), com foco em leituras de temperatura. O fluxo contempla desde a obtenção dos dados em formato CSV, passando pelo processo de ETL com Python, armazenamento em banco de dados PostgreSQL executado em contêiner Docker, criação de views SQL para análise e validação por meio de um dashboard interativo em Streamlit.

O dataset utilizado foi o **Temperature Readings: IoT Devices**, disponível no Kaggle. Ele contém registros de temperatura coletados por dispositivos IoT, incluindo informações como identificador da leitura, identificação da sala, data/hora do registro, temperatura e classificação da medição como interna ou externa.

Objetivo

Desenvolver um pipeline de dados capaz de:

- ler dados brutos em CSV
- realizar limpeza e transformação dos dados
- armazenar os registros em um banco PostgreSQL
- criar views analíticas para exploração dos dados
- validar os resultados por meio de um dashboard interativo

Tecnologias Utilizadas

As tecnologias empregadas neste projeto foram:

- **Python**: linguagem principal utilizada para o desenvolvimento do processo ETL
- **Pandas**: biblioteca utilizada para leitura, limpeza, transformação e manipulação dos dados

- **SQLAlchemy**: biblioteca ORM utilizada para realizar a conexão entre a aplicação Python e o banco PostgreSQL
- **PostgreSQL**: sistema de gerenciamento de banco de dados relacional utilizado para armazenamento dos dados
- **Docker**: plataforma utilizada para executar o banco de dados em um contêiner isolado, garantindo portabilidade e padronização do ambiente
- **Streamlit**: framework utilizado para construção do dashboard interativo de validação dos dados
- **Plotly**: biblioteca utilizada para geração de gráficos interativos dentro do dashboard
- **Kaggle / KaggleHub**: plataforma utilizada para obtenção do dataset de temperatura de dispositivos IoT

Dataset Utilizado

O conjunto de dados utilizado foi: **Temperature Readings: IoT Device,** esse dataset contém registros de temperatura associados a dispositivos/salas monitoradas, incluindo as seguintes colunas principais:

- id: identificador textual único da leitura
- room_id/id: identificação do ambiente ou dispositivo
- noted_date: data e hora da leitura
- temp: temperatura registrada
- out/in: classificação da leitura como interna (In) ou externa (Out)

Durante o processo ETL, algumas colunas foram renomeadas para facilitar a manipulação:

- room_id/id → room_id
- out/in → location_type

Estrutura do Projeto

A estrutura base do projeto foi organizada da seguinte forma:

```
.
├── data
│   └── IOT-temp.csv
├── docs
│   └── Disruptive Architectures_ IOT, Big Data e IA.docx.pdf
├── sql
│   ├── 01_schema.sql
│   └── 02_views.sql
├── src
│   ├── graphic1.png
│   ├── graphic2.png
│   ├── graphic3.png
│   └── logo_universidade.png
├── README.md
├── app.py
├── dir.md
├── download_data.py
├── etl.py
└── requirements.txt

5 directories, 14 files
```

Descrição dos Arquivos

- data/IOT-temp.csv Arquivo CSV com os dados brutos extraídos do dataset do Kaggle.
- sql/01_schema.sql Script responsável por recriar a tabela principal do banco de dados.
- sql/02_views.sql Script com a criação das views analíticas utilizadas no projeto.
- etl.py Script Python responsável pelo processo ETL: leitura do CSV, limpeza, transformação, carga no PostgreSQL e execução dos scripts SQL.
- app.py Script Streamlit responsável por exibir gráficos e tabelas para validação dos dados carregados e analisados.

- download_data.py Script para baixar o conteudo do Kaggle para uma planilha CSV no diretório data/.
- requirements.txt Lista das dependências Python utilizadas no projeto.
- README.md Documentação detalhada do projeto.

Arquitetura do Pipeline

O pipeline implementado segue o fluxo abaixo:

Dataset Kaggle

↓

Arquivo CSV

↓

Script ETL em Python

↓

PostgreSQL em Docker

↓

Views SQL

↓

Dashboard Streamlit

Explicação do Fluxo

1. O dataset é obtido e armazenado localmente em formato CSV.
2. O script etl.py faz a leitura do arquivo.
3. Os dados passam por limpeza, padronização e transformação.
4. A tabela do PostgreSQL é recriada por meio do script SQL.
5. Os dados tratados são inseridos no banco.
6. As views analíticas são criadas.
7. O dashboard consulta essas views e exibe as análises.

Configuração do Ambiente

1. Criar e ativar o ambiente virtual

No terminal, dentro da pasta do projeto:

```
python -m venv venv
source venv/bin/activate
```

Em sistemas Windows:

```
venv\Scripts\activate
```

2. Instalar as dependências

```
pip install -r requirements.txt
```

Configuração do Banco de Dados com Docker

O banco PostgreSQL é executado em um contêiner Docker.

Subir o contêiner PostgreSQL

```
docker run --name postgres-iot \
  -e POSTGRES_PASSWORD=postgres \
  -e POSTGRES_USER=postgres \
  -e POSTGRES_DB=iot_db \
  -p 5432:5432 \
  -d postgres
```

Verificar se o contêiner está em execução

```
docker ps
```

Acessar o PostgreSQL no contêiner

```
docker exec -it postgres-iot psql -U postgres -d iot_db
```

Download do arquivo

1. Download do CSV direto do kaggle

O script **download_data.py** faz o download de um dataset do Kaggle e copia um arquivo CSV para uma pasta local denominada data/. O fluxo é o seguinte:

1. **Cria uma pasta data** (caso não exista) para armazenar arquivos.
2. **Baixa um dataset do Kaggle** usando a biblioteca **KaggleHub**.
    - Dataset usado: **Temperature Readings from IoT Devices**.
3. **Procura arquivos .csv** dentro da pasta do dataset baixado.
4. **Seleciona o primeiro CSV encontrado**.
5. **Copia esse CSV para a pasta data** com o nome IOT-temp.csv.
6. **Exibe no terminal** o caminho do arquivo original e o caminho final onde ele foi salvo.

Processo ETL

O script etl.py realiza as seguintes etapas:

1. Leitura do arquivo CSV

O CSV localizado em data/IOT-temp.csv é lido com Pandas.

2. Normalização dos nomes das colunas

Os nomes das colunas são convertidos para minúsculo e padronizados.

3. Renomeação das colunas

Para manter consistência no pipeline, duas colunas são renomeadas:

- room_id/id para room_id
- out/in para location_type

4. Transformações aplicadas

São realizadas as seguintes transformações:

- conversão do campo id para texto
- limpeza de espaços em branco
- conversão do campo noted_date para datetime
- conversão do campo temp para numérico
- padronização do campo location_type para minúsculo

5. Regras de limpeza

Os dados passam pelas seguintes regras:

- remoção de registros com campos nulos essenciais
- filtro para manter apenas in e out em location_type
- remoção de registros duplicados com base na coluna id

6. Recriação da tabela

O script executa sql/01_schema.sql, responsável por remover e recriar a tabela principal com CASCADE, garantindo consistência a cada carga.

7. Inserção dos dados

Após a criação da tabela, os registros tratados são inseridos no PostgreSQL.

8. Criação das views

Ao final, o script executa sql/02_views.sql para disponibilizar as views analíticas no banco.

Esquema da Tabela Principal

A tabela principal criada no PostgreSQL é:

```
CREATE TABLE iot_temperature_readings (
    id TEXT PRIMARY KEY,
    room_id VARCHAR(100),
    noted_date TIMESTAMP,
    temp NUMERIC(10,2),
    location_type VARCHAR(10)
);
```

Justificativa do Tipo da Coluna id

Embora inicialmente fosse esperado um identificador numérico, o dataset possui IDs textuais, como por exemplo:

```
__export__.temp_log_196134_bd201015
```

Views Criadas

O projeto inclui três views analíticas principais utilizadas pelo dashboard.

1. avg_temp_por_dispositivo

Calcula a **temperatura média por dispositivo (sala)**, permitindo identificar quais ambientes apresentam temperaturas mais altas ou mais baixas.

2. leituras_por_hora

Mostra a **quantidade de leituras registradas por hora do dia**, ajudando a entender a distribuição das medições ao longo do tempo.

3. temp_max_min_por_dia

Apresenta a **temperatura máxima e mínima registrada em cada dia**, permitindo acompanhar variações térmicas ao longo do período monitorado.

Essas views são utilizadas diretamente pelo dashboard desenvolvido com **Streamlit**, que consulta os dados armazenados no **PostgreSQL** e gera visualizações interativas utilizando **Plotly**.

Dashboard Streamlit

O dashboard foi criado para validar o processo e visualizar os dados de forma simples.

Principais gráficos do dashboard

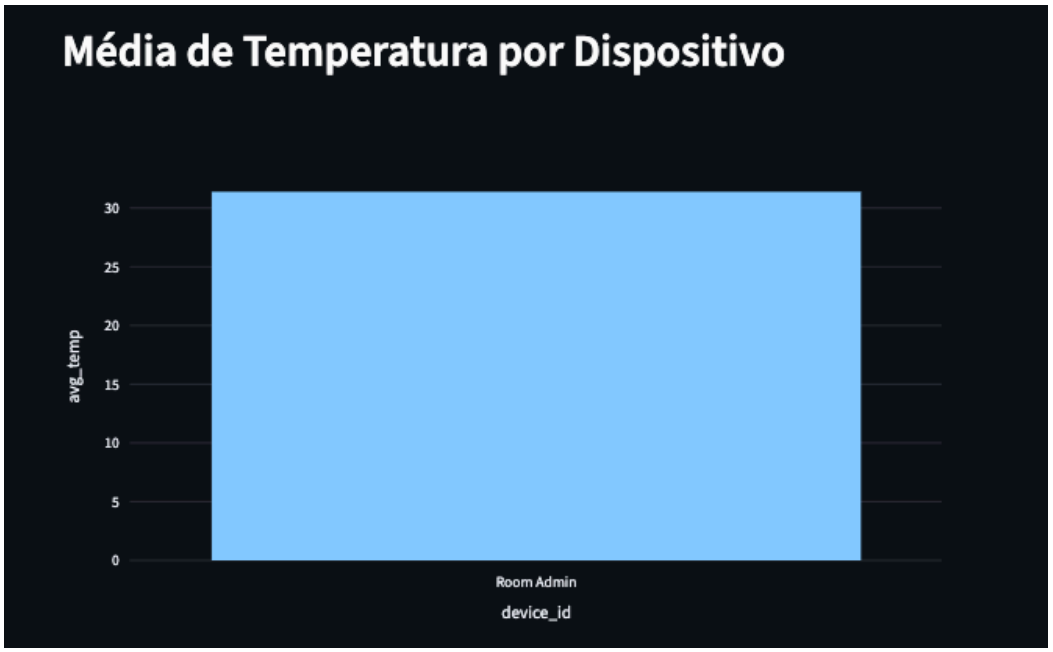

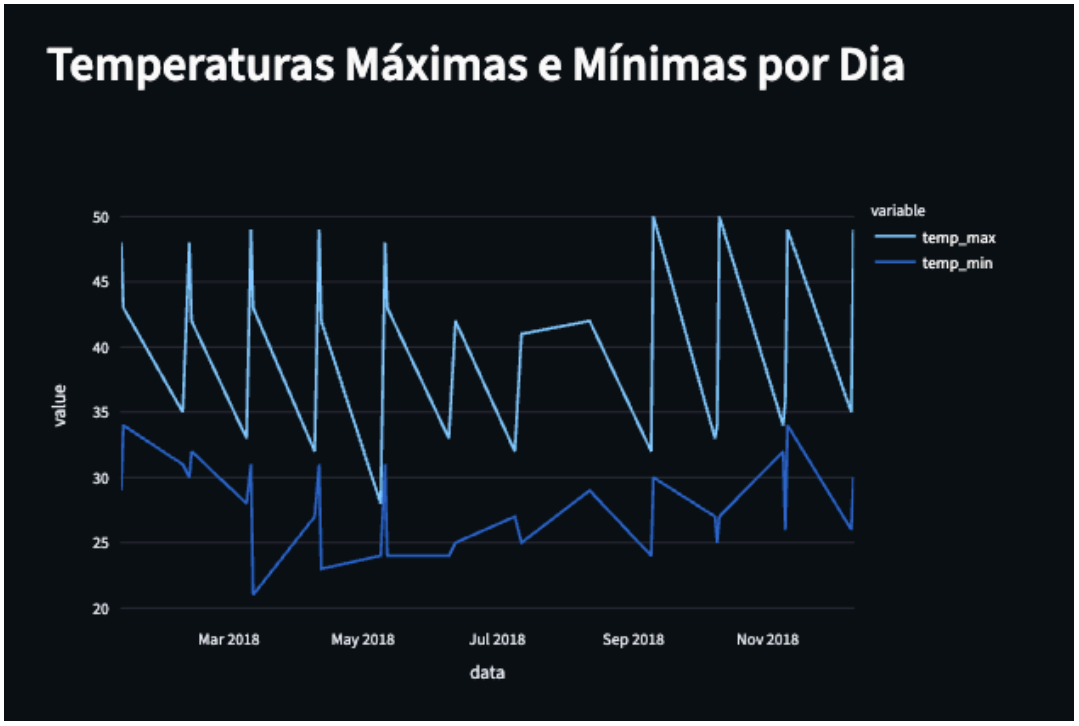

Executar o dashboard

```
streamlit run app.py
```

Após executar, o Streamlit abrirá uma interface no navegador, normalmente em:

```
http://localhost:8501
```

Como Executar o Projeto Completo

Passo 1: ativar o ambiente virtual

```
source venv/bin/activate
```

Passo 2: subir o PostgreSQL no Docker

```
docker run --name postgres-iot \
  -e POSTGRES_PASSWORD=postgres \
  -e POSTGRES_USER=postgres \
  -e POSTGRES_DB=iot_db \
  -p 5433:5432 \
  -d postgres
```

Passo 3: executar o ETL

```
python etl.py
```

Se tudo estiver correto, a saída esperada será semelhante a:

```
Lendo arquivo: /caminho/do/projeto/data/IOT-temp.csv
Total bruto no CSV: 97606
Registros após limpeza: 49943
Executando 01_schema.sql
Executando 02_views.sql
Carga finalizada com 49943 registros.
```

Passo 4: executar o dashboard

```
streamlit run app.py
```

Consultas de Validação no Banco

Alguns comandos úteis para validação no PostgreSQL:

Listar as tabelas

```
\dt
```

Listar as views

```
\dv
```

Consultar a tabela principal

```
SELECT * FROM iot_temperature_readings LIMIT 10;
```

Consultar média por localização

```
SELECT * FROM vw_avg_temp_by_location;
```

Consultar resumo diário

```
SELECT * FROM vw_daily_temp_summary LIMIT 10;
```

Resultados Obtidos

O pipeline conseguiu:

- carregar o dataset bruto em CSV
- realizar limpeza e padronização dos dados
- persistir os dados em PostgreSQL
- estruturar consultas analíticas com views
- disponibilizar visualização por meio de dashboard

Isso demonstra a construção de um pipeline de dados completo, com etapas de ingestão, transformação, armazenamento, modelagem analítica e visualização.

Principais Aprendizados

Durante o desenvolvimento, alguns pontos importantes foram identificados:

- necessidade de validar o tipo real das colunas do dataset
- importância da padronização dos nomes dos campos
- necessidade de controlar dependências entre tabela e views
- importância de organizar a carga em etapas previsíveis
- uso de Docker para padronização do ambiente do banco

Dificuldades Encontradas

Ao longo do desenvolvimento, foram observados alguns desafios:

- conflito de porta 5432 já utilizada na máquina, sendo necessário mudar a porta externa no comando docker
- diferenças entre o tipo esperado e o tipo real da coluna id
- erro ao recriar views existentes com estrutura diferente
- necessidade de usar CASCADE para remover dependências entre tabela e views

- necessidade de adaptar o dashboard às views realmente existentes no banco

Possíveis Melhorias Futuras

Como evolução do projeto, podem ser implementadas as seguintes melhorias:

- uso de docker-compose para facilitar a subida dos serviços
- modularização maior do ETL em arquivos separados
- adição de logs estruturados
- criação de testes automatizados
- versionamento do schema do banco
- inclusão de mais métricas analíticas
- containerização também do dashboard Streamlit

Principais Insights e Aplicações Práticas

A análise das leituras de temperatura dos dispositivos IoT permitiu identificar alguns padrões importantes.

Insights Obtidos

- **Diferença entre ambientes internos e externos:** temperaturas externas apresentam maior variação ao longo do dia, enquanto ambientes internos tendem a ser mais estáveis.
- **Ciclo térmico diário:** as temperaturas geralmente são mais baixas pela manhã, aumentam ao longo do dia e atingem o pico no período da tarde.
- **Comportamento por ambiente:** algumas salas apresentam médias de temperatura diferentes, o que pode indicar fatores como ventilação, incidência solar ou presença de equipamentos que geram calor.
- **Regularidade das medições:** a frequência constante das leituras indica que o sistema de coleta de dados é consistente.

Possíveis Aplicações em Cenários Reais

O pipeline desenvolvido pode ser aplicado em diversos contextos de monitoramento com sensores IoT, como:

- **edifícios inteligentes**, para otimizar sistemas de climatização e reduzir consumo de energia
- **ambientes industriais**, para monitoramento de equipamentos e prevenção de superaquecimento
- **cadeia fria**, no controle de temperatura de alimentos, vacinas e medicamentos
- **agricultura de precisão**, para monitoramento ambiental em estufas ou plantações

Essas aplicações demonstram como pipelines de dados com sensores IoT podem apoiar decisões operacionais e melhorar o controle de ambientes monitorados.

Conclusão

O projeto atingiu o objetivo de construir um pipeline de dados aplicado a um contexto de IoT. Foi possível extrair dados de um dataset real, tratá-los com Python, armazená-los em PostgreSQL executado em Docker, criar views para análise e validar os resultados em um dashboard.

Além de atender aos requisitos propostos, o projeto também proporcionou experiência prática com integração entre diferentes ferramentas amplamente utilizadas em engenharia de dados, análise de dados e visualização.